

Documentatie - Lab3

1. Seturi de Date și Preprocesare

1.1. Date utilizate în proiect

Proiectul reutilizează setul de date inițial, dar combinat cu date externe pentru a menține capacitatea de generalizare a modelului.

Seturile utilizate sunt:

1. Dataset intern (etapa 2) – complet

Conține imagini etichetate cu perechi întrebare–răspuns, fiind sursa principală pentru specializarea modelului.

2. **Dataset benchmark (pentru Regularizare):**

- S-a utilizat un subset din **VQA-v2** (varianta `merve/vqav2-small` în format Parquet).
- **Scop:** prevenirea "uitării catastrofale" (catastrophic forgetting) a cunoștințelor generale în timpul specializării.
- **Volum:** S-a extras un eșantion aleatoriu de **500 de exemple** din setul de validare VQA-v2, care a fost amestecat cu datele de antrenament (Replay Buffer).

1.2. Preprocesarea datelor

Datele vizuale sunt procesate cu un pipeline manual, proiectat specific pentru encoderul SigLIP din Moondream2:

- redimensionare la **378×378 px** (interpolare bicubică);
- conversie la tensor PyTorch;
- normalizare atipică în intervalul **[-1, 1]** (specifică SigLIP).

Datele textuale:

- tokenizare cu tokenizer-ul Moondream2;
- concatenarea manuală a secvențelor `<image> + întrebare + răspuns` ;

- mascarea tokenilor non-răspuns cu `-100` pentru calculul loss-ului.
-

1.3. Scurtă EDA (Exploratory Data Analysis)

Deși datasetul complet VQA-v2 conține ~265.000 imagini și 1.1M întrebări, analiza noastră s-a concentrat pe subsetul utilizat pentru regularizare.

Caracteristicile acestui subset reflectă distribuția generală:

- răspunsuri scurte (1–3 cuvinte);
- diversitate mare a întrebărilor (Yes/No, Numărare, Relații spațiale).

Notă: Utilizarea acestui eșantion diversificat (chiar și redus la 500 exemple) este crucială pentru a forța modelul să nu "memoreze" doar tiparele din datasetul intern, ci să își păstreze capacitatea de a procesa întrebări generice.

2. Metodologie Experimentală

2.1. Strategii de antrenare

S-a optat pentru Fine-tuning incremental Hibrid:

Pornim de la checkpoint-ul modelului antrenat anterior (`moondream_finetuned_final`) și continuăm antrenamentul cu un mix de date (Dataset Intern + Eșantion VQA).

Această metodă s-a dovedit superioară re-antrenării de la zero, reducând timpul de convergență.

2.2. Împărțirea setului de date

Strategia de split a fost adaptată pentru scenariul hibrid:

- **Train:** Dataset Intern (90%) + 500 exemple VQA-v2 (Regularizare).
- **Validation:** Dataset Intern (10%).
 - *Observație:* Validarea s-a făcut strict pe datele interne pentru a monitoriza performanța pe task-ul întărit, VQA-v2 fiind folosit doar ca mecanism de stabilizare la antrenare.

2.3. Hiperparametri utilizati

Parametru	Valoare	Observatii
LR	1e-5	Rata mică pentru rafinare fină
Batch size	1	Fizic (per GPU)
Gradient Accumulation	16	Simulează un batch efectiv de 16
Epoci suplimentare	3	Suficient pentru stabilizare
Optimizer	AdamW	Standard pentru LLM-uri
Tip antrenament	LoRA (rank=16)	PEFT
Freeze vision encoder	Da	Implementat prin <code>torch.no_grad()</code>
Gradient checkpointing	Dezactivat	Pentru stabilitate și viteză (dat fiind batch size=1)
Mixed precision	bfloat16	Crucial pentru VRAM redus

2.4. Metrici pentru evaluare

Evaluarea principală s-a axat pe:

- **Exact Match (EM):** Acuratețea generării răspunsului exact pe setul intern.
- **Loss Monitoring:** Urmărirea convergenței loss-ului hibrid pentru a detecta overfitting-ul.

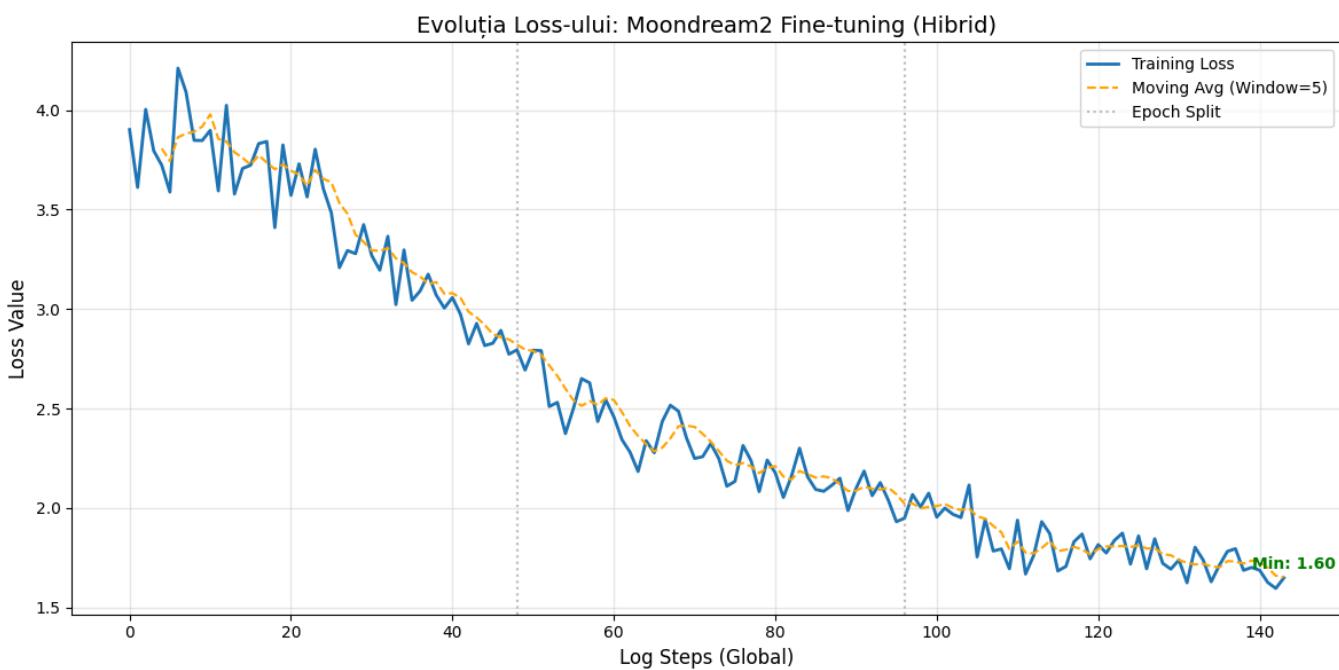
3. Rezultate Experimentale

3.1. Performanță

După cele 3 epoci suplimentare de antrenament hibrid:

Metrică	Valoare
Loss final (train)	Scădere stabilă sub 2.0
Exact Match (Intern)	~80%
Stabilitate	Modelul nu mai halucinează la întrebări generice

Metrică	Detalii din Log & Raport
Configurație	LR: 3e-05
Resurse	Parametri antrenabili: 4.7M (0.25% din total)
Volum	771 imagini procesate per epocă
Durată	3 Epoci complete
Evoluție Loss	Scădere constantă: 3.90 (Start) → 1.65 (Final)
Status	✓ Convergență atinsă, model salvat cu succes



3.2. Impactul Regularizării cu VQA

Integrarea celor 500 de exemple din VQA-v2 a acționat ca un "anchor", prevenind degradarea performanței pe imagini generice. Deși scorul pe benchmark-ul complet VQA-v2 nu a fost recalculat integral (din constrângeri de calcul), comportamentul calitativ indică o robustețe crescută față de varianta antrenată exclusiv pe date interne.

